

churn 모델

<4/30 8:07 업데이트>

TRAIN 0.8062

VAILD 0.8013

앙상블 : 절사값0.35, VOTING,SVM 의미X

챔피언	이름	알고리...	ROC 아...	정확도	평균제...	누적향...	누적반...	점수
★	앙상블	앙상블	0.8013	0.9131	0.0708	3.9179	39.1793	0.8013
	GB (1)	그래디언트 부스팅	0.8007	0.9131	0.0709	3.8617	38.6172	0.8007
	GB (2)	그래디언트 부스팅	0.8001	0.9134	0.0708	3.8898	38.8983	0.8001
	GB (4)	그래디언트 부스팅	0.8001	0.9131	0.0709	3.9348	39.3479	0.8001
	GB (3)	그래디언트 부스팅	0.8013	0.9131	0.0708	3.9882	39.8820	0.8013
	GB	그래디언트 부스팅	0.8010	0.9128	0.0708	3.9067	39.0669	0.8010

적합통계량


타겟 이름	데이터 역할	분할 표시자	출력형식이 지정된 분할
target_churn	TRAIN	1	1
target_churn	VALIDATE	0	0

관측값 수	평균제곱오차	ASE의 분모	제곱근평균제곱오차
42,000	0.0691	42,000	0.2629
18,000	0.0708	18,000	0.2660

오분류 비율	다중 Class 로그 손실	KS(Youden)	ROC 아래면적
0.0840	0.2483	0.4902	0.8062
0.0869	0.2522	0.4991	0.8013

Gini 계수	감마	Tau	KS 절사값
0.6123	0.6433	0.1091	0.0800
0.6026	0.6332	0.1073	0.1100

사용자 지정 절사값에서의 KS	KS 절사값에서의 오분류 비율(이벤트)	오분류 비율(이벤트)
0.1874	0.2124	0.0840
0.1714	0.1867	0.0869



<4/28 8:17 업데이트>

5-



fold CV 진행결과 : 변수선택 -> **GB 0.80064**

챔피언	이름	알고리즘...	ROC 아...	정확도	평균제곱...	누적합...	누적반응...
★	GB (3)	그래디언트 부스팅	0.8013	0.9131	0.0708	3.9882	39.8820
	GB (1)	그래디언트 부스팅	0.8007	0.9131	0.0709	3.8617	38.6172
	GB (2)	그래디언트 부스팅	0.8001	0.9134	0.0708	3.8898	38.8983
	GB (4)	그래디언트 부스팅	0.8001	0.9131	0.0709	3.9348	39.3479
	GB	그래디언트 부스팅	0.8010	0.9128	0.0708	3.9067	39.0669

1. 변수 역할과 레벨 설정

target_churn: Target / Binary

customer_id: ID / Nominal

target_ltv, target_ltv_log: Rejected / Interval

gender, is_married: Input / Binary

income_group, prefer_category, region_code: Input / Nominal

나머지 거래금액, 거래건수, 잔고, 비율, 점수, 기간, 일수, 개수 변수: Input / Interval

☐	변수 이름 ↑	역할	레벨
☐	active_months_6m	Input	Interval
☐	age	Input	Interval
☐	amt_month_slope	Input	Interval
☐	card_cash_service_amt_0	Input	Binary
☐	card_cash_service_amt_log	Input	Interval
☐	card_loan_amt_log	Input	Interval
☐	category_nunique_6m	Input	Interval
☐	credit_score	Input	Interval
☐	customer_id	ID	Nominal
☐	days_since_last_txn	Input	Interval
☐	fin_asset_trend_score	Input	Interval
☐	fin_overdue_days	Input	Interval
☐	gender	Input	Binary
☐	income_group	Input	Nominal
☐	installment_ratio_6m	Input	Interval
☐	is_married	Input	Binary
☐	loan_to_deposit_cut	Input	Interval
☐	net_balance	Input	Interval
☐	num_active_cards	Input	Interval
☐	online_ratio_6m	Input	Interval
☐	prefer_category	Input	Nominal
☐	recent_amt_share_1m	Input	Interval
☐	recent_amt_share_3m	Input	Interval
☐	region_code	Input	Nominal
☐	target_churn	Target	Binary
☐	target_ltv	Rejected	Interval
☐	target_ltv_log	Rejected	Interval
☐	tenure_days	Input	Interval
☐	total_deposit_balance_log	Input	Interval
☐	total_loan_balance_log	Input	Interval
☐	txn_amt_mean_6m	Input	Interval
☐	txn_amt_std_6m	Input	Interval
☐	txn_amt_sum_1m	Input	Interval
☐	txn_amt_sum_3m	Input	Interval
☐	txn_amt_sum_6m	Input	Interval
☐	txn_cnt_1m	Input	Interval
☐	txn_cnt_3m	Input	Interval
☐	txn_cnt_6m	Input	Interval

1.2 프로젝트 설정

- 데이터 분할 : 프로젝트 설정 - 데이터 분할 70: 30 - 방법:층화

층화 분할: **target_churn**이 0/1이잖아. 예를 들어 전체 데이터가 이런 비율이라고 해보자: 유지(0): 90% 이탈(1): 10% / 그런데 아무 생각 없이 랜덤 분할하면 **Validation** 쪽에 이탈 고객이 너무 적거나 많아질 수 있어. 그래서 **target_churn**의 0/1 비율을 **Train**과 **Validation**에 비슷하게 맞춰서 나누는 것이 층화 분할이야. 예:전체: 0이 90%, 1이 10% / Train도: 0이 90%, 1이 10% / Validation도: 0이 90%, 1이 10% 층화 분할을 안 하면 어떤 쪽에는 이탈 고객이 너무 적고 어떤 쪽에는 너무 많아서 성능 평가가 흔들릴 수 있어. 그래서 **target_churn** 기준으로 **stratified partition** 하라고 한 거야.

프로젝트 설정

데이터 분할

이벤트 기반 표본추출

노드 구성

규칙

출력 라이브러리

로깅

컴퓨팅 컨텍스트

데이터 분할

분할변수 생성

참고: 이 설정은 분할변수가 데이터 내에 설정되지 않을 때만 활성화됩니다. 미리 정의된 분할변수가 있는 데이터 소스를 사용하거나 분할변수를 수동으로 선택하면 설정이 재정의됩니다.

방법:

증화

학습: *

70

70.00%

검증: *

30

30.00%

테스트: *

0

0.00%

저장 취소

● 규칙

Class 모델 선택 통계량: 곡선아래면적(C 통계량)

이유: SAS에서 C 통계량은 이진분류에서 사실상 ROC-AUC와 같은 계열이라서, 대회 평가 기준과 가장

프로젝트 설정

데이터 분할

이벤트 기반 표본추출

노드 구성

규칙

출력 라이브러리

로깅

컴퓨팅 컨텍스트

규칙

모델 비교

Class 모델 선택 통계량:

곡선아래면적(C 통계량)

Interval 모델 선택 통계량:

평균제곱오차

모델 선택 분할:

기본

기본 선택은 사용 가능 여부에 따라 테스트, 검증, 학습 순입니다.

모델 선택 깊이:

10

ROC 기반 질사값:

0.50

모델

저장 취소

직접적으로 맞아.


2. 알고리즘 탐색

2.1 챔피언 모델 선정 - 그래디언트부스팅

대회 평가 기준인 ROC-AUC를 1순위 지표로 적용하여 초기 4개 모델의 성능을 비교 분석했습니다.

● 핵심 지표: VALIDATE ROC 아래면적 (AUC)

- 보조 지표: Train vs Validate AUC 차이 (과적합 진단)



모델명	VALIDATE AUC (성능 순위) (test)	TRAIN AUC (train)	AUC 차이 (과적합 진단) (test-train)	주요 해석 및 결론
그래디언트 부스팅	0.7929 (1위)	0.8306	약 0.038 (양호)	챔피언 모델 선정. 성능이 가장 우수하며 과적합 신호가 적어 가장 균형 잡힌 모델.
랜덤 포리스트	0.7850 (2위)	0.8960	약 0.111 (주의)	훈련 성능이 매우 높으나 검증에서 크게 하락. 과적합 신호가 강함. 튜닝을 통한 완화 필요.
의사결정트리	0.7604 (3위)	0.7558	차이 작음 (안정적)	성능은 낮으나 과적합은 없음. 기본 모델로 활용 가능.
로지스틱 회귀	0.7294 (4위)	0.7203	차이 작음 (안정적)	성능이 가장 낮음. 선형 모델의 한계.

초기 성능 해석:

- 챔피언 모델 선정 (AUC 기준): 그래디언트 부스팅 모델이 검증 AUC 0.7929로 가장 우수하며, 보조 지표인 KS도 0.4962로 가장 높아 제출용 챔피언 모델로 우선 선정합니다.
- 과적합 진단: 랜덤 포리스트는 Train AUC가 0.8960으로 높으나 Validate AUC와의 차이가 0.111로 커서 과적합 신호가 강하게 나타났습니다. 그래디언트 부스팅은 상대적으로 그 차이가 0.038로 양호한 편입니다.

3. **Accuracy/F1 해석:** 데이터 불균형으로 인해 **Accuracy**만으로는 모델 성능을 정확히 판단하기 어려우며, 현재 **F1-Score**는 절사값(**Cutoff**) **0.5** 기준으로 낮게 측정되었으나, **AUC** 및 **KS** 성능이 우수하므로 확률 정렬 능력은 높다고 판단합니다.

-그래디언트 부스팅 하이퍼파라미터 튜닝 후 성능이 정체될 시 파생변수를 추가하는 순으로 작업 진행(파생변수는 시간이 더 많이 들고, 잘못 만들면 오히려 잡음이 늘어날 수도 있음)

조기중지 옵션 **on** & 로그손실

- 더 학습해도 성능이 안 좋아지면 일찍 멈추는 장치. **GB**는 트리를 계속 추가하면서 학습하니깐, 너무 오래 가면 훈련 데이터에 과하게 맞춰질 수 있어. 즉, 성능 + 시간 + 과적합 방지 때문에 켜는 거야.

오분류 비율의 문제 오분류 비율은 보통 **0.5** 절사값 기준이야. 즉 예측확률이 **0.49, 0.30, 0.10** 이 셋은 전부 **0**으로 잘려서 같은 취급이 될 수 있어.


근데 **churn** 대회는 확률 순서가 중요하잖아. **AUC**는 “누가 더 위험한 고객인지”를 얼마나 잘 정렬했는지를 봐. 로그손실은 예측확률 자체를 반영해. 실제 이탈 고객에게 **0.49**를 줬는지 **0.10**을 줬는지 차이를 반영해. 오분류율보다 확률 예측 품질을 더 잘 반영해.

데이터 탐색에서 변수 중요도 및 상관관계 파악

gb: 파라미터 지정, 절사값 변경(이벤트 분류 창에서 다양한 겨우 볼 수 있음)

모델비교:

2.2 GB 모델 선정 - Gradient Boosting_Mix 0.7966



모델 비교

챔피언	이름	알고리즘 이름	ROC 아래면적
true	Gradient Boosting_Mix	그래디언트 부스팅	0.7966
false	그래디언트부스팅	그래디언트 부스팅	0.7929
false	그래디언트 부스팅-light gbm 모드	LightGBM	0.7934
false	GB	그래디언트 부스팅	0.7933
false	Gradient Boosting_2_leaves	그래디언트 부스팅	0.7946

2.3 절사값 변경

챔피언	이름	알고리...	ROC 아...	정확도	평균제...
★	Gradient Boosting_Mix (1)	그래디언트 부스팅	0.7966	0.9129	0.0721
	Gradient Boosting_Mix 절사값0.3	그래디언트 부스팅	0.7966	0.9129	0.0721
	Gradient Boosting_Mix 변수 관리	그래디언트 부스팅	0.7956	0.9138	0.0712

1. 0.5
2. 0.3

3. 0.5+하위변수 **is_married**(결혼 여부), **gender**(성별), **region_code**(거주 지역) 3개 제외.
- 4.

2.4 하이퍼 파라미터 튜닝

2.4 하이퍼 파라미터 튜닝 비교 및 추천 (그래디언트 부스팅)

파라미터	1안. 균형형 (1순위 추천)	2안. 보수형 (과적합 완화)	3안. 공격형 (성능 극대화)
목표 해석	과적합과 성능의 균형. 가장 먼저 시도	과적합 최소화, 안정적 결과 유도	패턴 적극 탐색, Recall/AUC 향상 시도
트리 수	150	100	250
학습률	0.05	0.03	0.03
부분 표본 비율	0.8	0.8	0.6
L1 정규화	0.1	0.3	0.05
L2 정규화	0.3	0.8	공란
최대 가지 수	3	2	4
최대 깊이	4	3	5
최소 리프 크기	20	30	10
타깃 분포	이항 또는 churn용 분류 옵션	공란	공란
시드	12345	12345	12345
결측값 처리	탐색에 사용	탐색에 사용	탐색에 사용
최소 결측값	1	공란	공란
Interval 구간 수	50	50	50

-----> 파생변수 & 데이터 마이닝 사전처리 로 모델 성능 향상시키는 방향으로 가야 함.

2.2 데이터 마이닝 사전처리

변수관리, 변수선택, 변환 etc..

모델 비교					
챔피언	이름	알고리...	ROC 아...	정확도	평균제..
★	Gradient Boosting_Mix	그래디언트 부스팅	0.7996	0.9137	0.07
	포리스트	포리스트	0.7924	0.9138	0.07
	의사결정트리	의사결정트리	0.7613	0.9127	0.07
	앙상블	앙상블	0.7957	0.9129	0.07

결과: Variable Selction2 + GB MIX 0.7996

3. 파이썬 연동

XGB(파이썬, 5-fold CV) 0.796681
Variable Selction2+XGB(파이썬, 5-fold CV) 0.796681
GB(파이썬, 5-fold CV) 0.748851
Variable Selction2 + GB(파이썬, 5-fold CV) 0.805787

3.1 파이썬 모델링 결과 분석 (AUC 기준)

모델명	AUC (5-fold CV)
XGB (파이썬)	0.796681 ▾
Var.Sel. 2 + XGB	0.796681 ▾
GB (파이썬)	0.748851 ▾
Var.Sel. 2 + GB	0.805787 ▾

최종 결론:

- **Variable Selection 2 + GB (파이썬)** 모델이 **AUC 0.805787**로 현재까지 가장 우수한 성능을 보였습니다. 해당 모델을 최종 제출 모델로 확정하고 추가적인 미세 튜닝을 진행할 예정입니다.
- 변수 선택(Variable Selection 2)은 특히 Gradient Boosting 계열 모델의 성능을 크게 끌어올리는 데 효과적이었습니다.


Todo

variable selection2 미세 조정하기! -> **sas viya** 도움말.

문제. cv 진행 전 결과임.

<4/28 8:17 업데이트>

5-fold CV 진행결과 : 변수선택 -> **GB 0.80064**



챔피언	이름	알고리즘...	ROC 아...	정확도	평균제곱...	누적항...	누적반응...
★	GB (3)	그래디언트 부스팅	0.8013	0.9131	0.0708	3.9882	39.8820
	GB (1)	그래디언트 부스팅	0.8007	0.9131	0.0709	3.8617	38.6172
	GB (2)	그래디언트 부스팅	0.8001	0.9134	0.0708	3.8898	38.8983
	GB (4)	그래디언트 부스팅	0.8001	0.9131	0.0709	3.9348	39.3479
	GB	그래디언트 부스팅	0.8010	0.9128	0.0708	3.9067	39.0669